

local_whisper_nemo

Portables Windows-11-Push-to-Talk-Diktat, vollständig offline.

Halte **Strg+Shift** gedrückt, sprich (am besten in ein Headset), lass los — der Text wird direkt dort eingetippt, wo dein Cursor steht (Word, Browser, Chat, ...). Die Spracherkennung läuft lokal mit NVIDIAs [nemotron-3.5-asr-streaming-0.6b](#) (40 Sprachen, Deutsch und Englisch inklusive).

Nichts verlässt deinen Rechner: Das Modell liegt im App-Ordner, und die laufende Anwendung stellt keine einzige Netzwerkanfrage.

Inbetriebnahme

Doppelklick auf **install.bat**. Das Skript legt ein portables **uv** und ein verwaltetes Python in **tools** ab, installiert die Abhängigkeiten, lädt das Modell nach **models** und erstellt eine Desktop-Verknüpfung.

Du brauchst weder **Admin-Rechte** noch ein **systemweites Python**. Netzwerkzugriff ist nur für diese einmalige Installation nötig — danach läuft alles offline.

Verwendung

Starte über die Desktop-Verknüpfung (oder **run.bat**). Die App läuft im Hintergrund und zeigt nur ein Icon im System-Tray.

- **Halten** von **Strg+Shift** → eine kleine Wellenform-Anzeige erscheint, solange aufgenommen wird.
- **Loslassen** → der Text wird transkribiert und an der Cursorposition eingetippt; die Anzeige verschwindet.
- **Beenden** über das Tray-Icon.

Beim ersten Start dauert es rund 45 Sekunden, bis das Modell im Speicher ist — erst danach reagiert der Hotkey.

Wenn du **mehr als ein Tastaturlayout** installiert hast, benutzt Windows **Strg+Shift** selbst zum Umschalten zwischen den Layouts. Trage in dem Fall in der **.env** einen anderen **HOTKEY** ein (z. B. **ctrl+alt+space**).

Gesprochene Formatierungsbefehle: *new line*, *next line*, *new paragraph*, *tab*.

Konfiguration

Kopiere **.env.example** nach **.env** und passe an, was du brauchst — Modell, Sprache (**de-DE**, **en-US**, **auto**), Gerät (**cpu/cuda**) und Hotkey. Details in [docs/configuration.md](#).

Tipp: Wenn du ausschließlich Deutsch diktierst, setze **ASR_LANGUAGE=de-DE**. Das spart die Spracherkennung und verhindert, dass das Modell mitten im Satz die Sprache wechselt.

Entwicklung

```
uv sync
uv run pytest -m "not slow"    # schnelle Unit-Tests
uv run pytest -m slow         # lädt das echte Modell
uv run python -m src.main      # aus dem Quellcode starten
```

Dokumentation

- [IMPLEMENTATION.md](#) — aktueller Implementierungsstand
- [docs/](#) — Details auf Komponentenebene

Lizenz

Apache-2.0. Das ASR-Modell wird von NVIDIA unter OpenMDW-1.1 bereitgestellt.